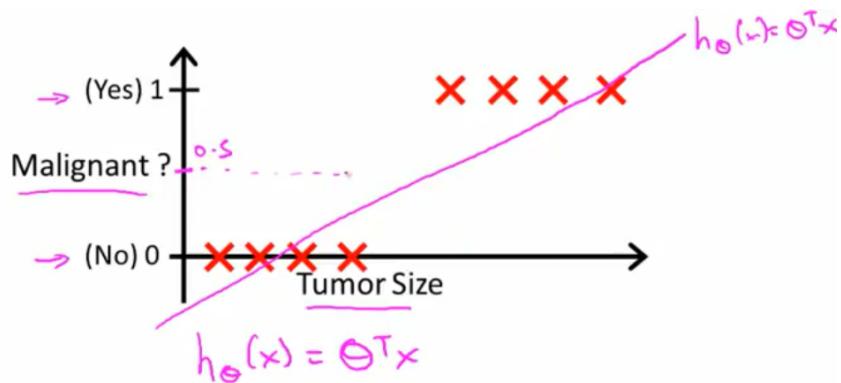


الأسبوع الثالث

Logistic Regression

- الكلاسيفيكاشن

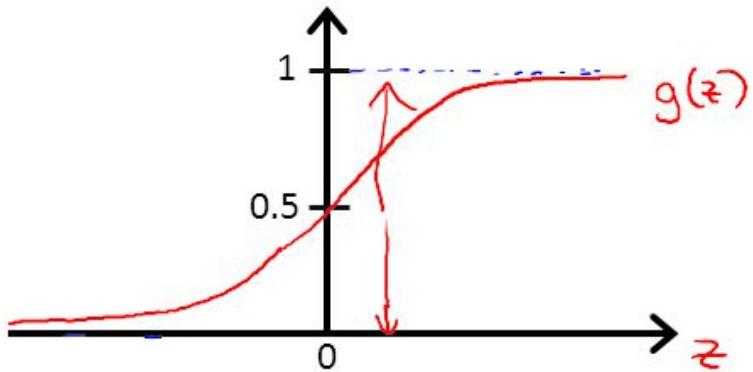
- هل الايميل ده حقيقي ولا سبام
- هل الورم خبيث ولا حميد
- هل تحويل الفلوس حقيقي ولا نصب
- غالبا يكون رقم 0 للنجاتيف ، و 1 للبوسيتيف
- اغلب المسائل تكون كلاسين فقط (0 و 1) وبعضها يكون اكثر من كلاس (. . . 5,4,3,2,1,0)



- لو عندي مجموعة نقط هي ورم حميد ، ومجموعة تانية ورم خبيث ، فلما اعمل خط يجمعهم بيست فيت لain زyi الريجريشن هيعمل لغبطة كبيرة ، ومش هيكون عندي امكانية اني اتوقع البيانات بشكل سليم ، فلازم اشوف حل تاني
- لازم قيمة الاتش في النهاية تكون بين الصفر والواحد ، مينفعش اكبر من 1 او اقل من صفر ، لأن الكلاسيفيكاشن بيقول هي يا صفر يا واحد ، عشان كدة هنعمل عملية logistic regression وللي هتحول ارقام النواتج من صفر لواحد
- اسم العملية logistic regression ملوش علاقة بالريجريشن اللي خدناه من شوية ، ده كلاسيفيكاشن
- ده بيتم عن طريق معادلة اسمها سيمجوميد وهي كالتالي

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

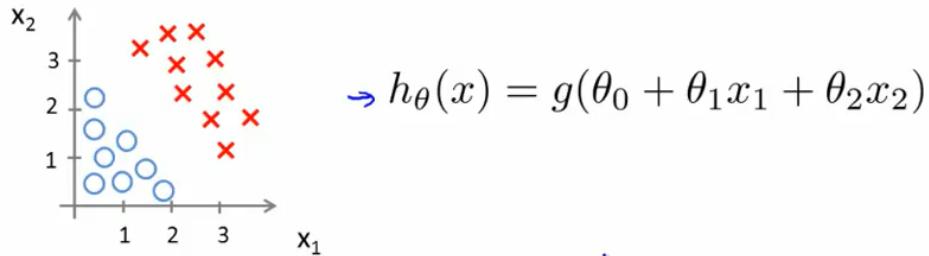
- قيمة ثيتا ترانسبوز في الاكس ، اعملها ميناس باور للاكسبونينيشيال ، بعدها اعمل 1 على 1 + القيمة ديه
- و هتكون رسمتها كدة



- لاحظ ان الاسيمتوت الاعلي هو 1 و الادني هو صفر, وده معناه ان كل قيم واي تتراوح من صفر واحد طيب هنا سؤال : المفترض ان النتيجة المطلوبة , تقسيم العناصر عندنا لنوعين , ورم حميد (0) او خبيث (1) , طيب لو طلعت النتيجة 0.7 , هنقسمها ازاي ؟
- ده معناها ان احتمالية ان يكون الورم خبيث 70 % , واحتمالية يكون حميد 30 %
- كذلك لو النتيجة 0.24 , يبقى احتمالية خبيث 24 % و حميد 76 %
- فيه اتجاه تاني وهو التقريب , ان لو قيمة الجي طلعت تساوي او اكبر من نص , فده معناها انها واحد (خبيث) لو اقل من نص , يبقى صفر (حميد)

- من الرسم , ومن الاكواشن , واضح ان الجي هتكون 1 , لما قيمة الزي توصل للانفينيتي , عشان e اس سالب انفينيتي هتساوي صفر , ف $1 / 1$ هتساوي واحد (**النصف الايمن من الرسم**) وفي حالة الزي تساوي صفر , اس صفر تساوي $1 / 1 + 1$, هتساوي نص , يعني في النص بالضبط في حال زي اقل من صفر , قيم سالبة , هيكون e اس موجب رقم اكبر من 1 يبقى واحد علي رقم اكبر من 2 يبقى اقل من النص لما الزي تبقى برقم سالب ضخم جدا (-1000 مثلًا) e اس موجب الف برقم كبير , يبقى 1 علي الرقم ده برقم يقترب من صفر (**النصف اليسير من الرسم**)
- لما الزي تكون بسالب انفينيتي , الـ e ه تكون اس انفينيتي , يعني انفينيتي , 1 علي انفينيتي تساوي صفر يعني من الاخر , على قد ما زي تكبر , الناتج يساوي 1 , على قد ما تصغر , يساوي صفر , لو بتساوي صفر , يبقى الجي بنص

- ناخد مثال عملي
 - عندنا الشكل ده , اللي فيه نقط عايزين نقسمهم , و الفنكشن بتاعتته معتمدة علي 3 ثيتات
 - هنفرض قيم لثيتنا صفر سالب 3 , ثيتنا 1 تساوي 1 و ثيتنا 2 تساوي 1



- فنكشن الاتش (القيمة المتوقعة والمطلوبة , زي السعر المتوقع) اللي عايزينها اكتر من صفر ه تكون كدة :

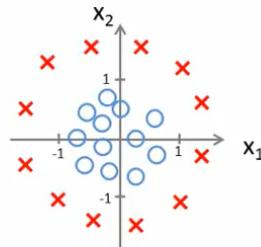
$$-3 + x_1 + x_2 \geq 0$$

- خ بالك ان اكس اتنين كانها واي , يعني ديه معادلة خطية هتمر بكلام من 3 و 3
- و ممكن اقول ان :

$$X_2 > 3 - X_1$$

- وكان كل القيم اللي فوق الخط ده هيكون 1 والقيم اللي تحته هيكون صفر

- مثل تاني , غير خطى
- الرسم ده :



- مش هيتفع نتعامل معاها تعامل الريجريشن الخطى , فمش هيتفع نفرض ثيتا 0 و 1 و 2 , عشان نحط اكسين , لكن عشان الرسم ده يشبه رسم الدائرة , فلازم اتعامل مع مربع كل اكس من اكس 1 و 2 , عشان كدة يكون الفرض فيه 5 ثيتات تغطي اربع اكسات كالتالي :

$$h_\theta(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

- ه تكون معادلة تربيعية , للاس الثاني , ولو فرضنا ان ثيتا 0 = سالب 1 , و كل امن ثيتا 1 و 2 = 0 , وكل امن ثيتا 3 و 4 = 1 , ه تكون كالتالي :

$$x_1^2 + x_2^2 \leq 1$$

- وهي معادلة دائرة , مركزها الاوريجين , ونص قطرها 1 , فاي قيمة ابعد من كدة تكون ايجابي , واي قيمة اصغر من كدة تكون سلبي

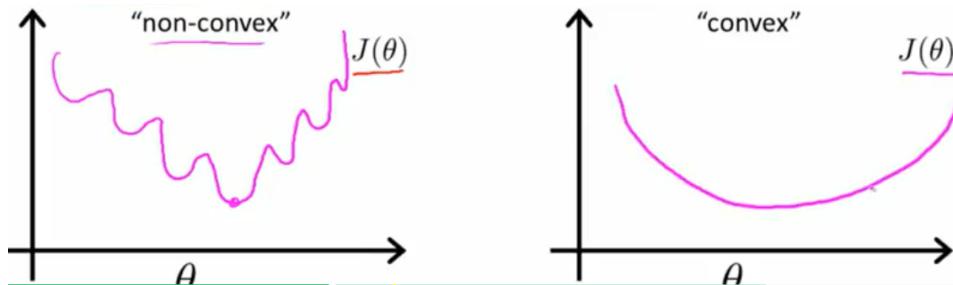
- ولاحظ ان وارد بيجي باراميترز اكتر من كدة , ويكون فيه اكسات و ثيتات كتير , فهتيجي اشكال معقدة

● مَاذَا عن المعادلة المستخدمة

○ مش هينفع نستخدم نفس معادلة الكوست المستخدمة في اللينيار اللي هي :

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} (h_\theta(x^{(i)}) - y^{(i)})^2$$

○ ديه مشكلتها انها هتعمل شكل غير متدرج (non convex) زي اللي علي الشمال. واللي هتصعب علينا جدا ايجاد اقل كوست , فلازم نشوف معادلة تانية عشان تعامل لنا شكل convex زي اللي علي الميني



○ فلازم نستخدم اللوجاريثم

○ المعادلة المستخدمة باللوجاريثم هي :

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_\theta(x^{(i)}), y^{(i)})$$

$$\text{Cost}(h_\theta(x), y) = -\log(h_\theta(x)) \quad \text{if } y = 1$$

$$\text{Cost}(h_\theta(x), y) = -\log(1 - h_\theta(x)) \quad \text{if } y = 0$$

○ الأول عايزين نفهم المعنى التطبيقي لمعنى ان ∇ تساوي صفر او واحد

الـ ∇ دايما بتكون القيمة الحقيقية المعطاة في الـ Training Data يعني عندي بيانات الف مريض

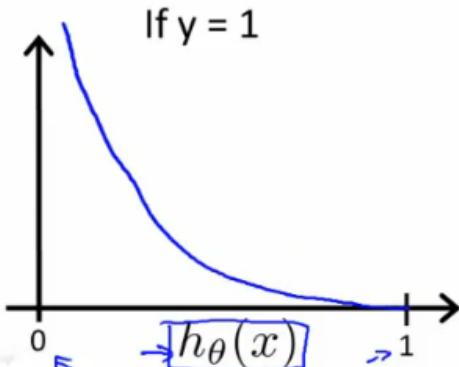
بالسرطان , بياناتهم الصحية وزنهم وعاداتهم في الاكل و ده كل ديه الـ X features

ببينما النتيجة النهائي , يا ترى هل هو مريض او لا هي قيمة الـ ∇

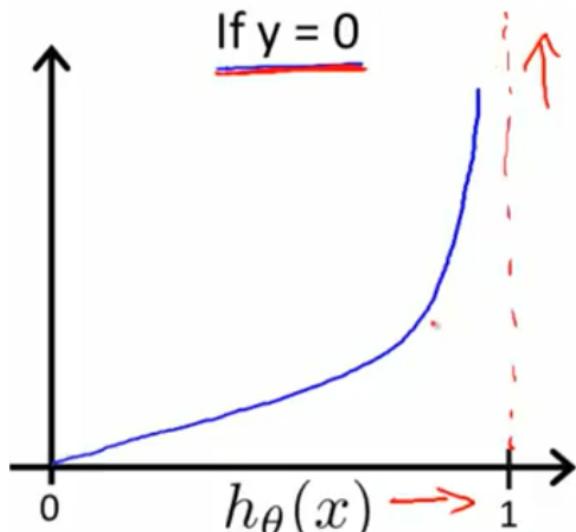
معني كدة ان كلمة ان ∇ تساوي صفر معناها بنتكلم عن الناس اللي معندهمش سرطان , او اللي بيتهم

متباعش , او اللي منجحش في الامتحان و هكذا, والعكس مع ∇ تساوي 1

○ في الحالة الأولى : y تساوي 1 ه تكون الرسمة كالتالي :



- محور اكس هو x اللي هو القيمة المتوقعة من الاكواشن (يعني سعر البيت المتوقع لمساحة كذا) , محور واي هو J اللي هو التكلفة الحقيقية (فرق السعر الحقيقي عن المتوقع سكوير علي ضعف الم) واضح ان لما كانت الاش تقترب من 1 (واحنا اصلا في حالة ان y تساوي 1) , فالتكلفة (اللي عايزين نقلها للصفر) بتقرب من صفر , ولما الاش تقترب من صفر , فالتكلفة بتزيد بشكل جنوني



- بينما في الحالة الثانية ($y=0$) لما نقل الاش , الكوست هتوصل لصفر , ولما توصل الاش لواحد , التكلفة هتوصل لأنفينيتي
- وممكن اجمع المعدلتين مع بعض هنا

$$\text{Cost}(h_\theta(x), y) = -y \log(h_\theta(x)) - (1-y) \log(1-h_\theta(x))$$

- لو عوضت عن الواي 1 هتجيباك المعادلة الاولى , لو عوضت بصفر هتجيباك الثانية , واللي هتأدي للمعادلة ديه

$$\begin{aligned} J(\theta) &= \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_\theta(x^{(i)}), y^{(i)}) \\ &= -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_\theta(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_\theta(x^{(i)})) \right] \end{aligned}$$

- نبدأ نحاول نجيب قيمة ثيتا اللي هتقل الـ J ، فنقول ان الثيتا هتساوي نفس الثيتا ناقص الفا في تقاضل الـ J ، واللي ه تكون كدة بعد الاختصار

$$\theta_j := \theta_j - \alpha \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

- واللي هنكررها كذا مرة لغاية لما نجيب قيمة ثيتا اللي هتجيب اقل قيمة لـ J
- و ده هيتعمل مع كل الثيتات ، من صفر لاعلي عدد
- و مع ان شكلها مطابق لشكل الفنكشن بتاعت الـ linear regression لكن هنا قيمة الاتش تختلف عن اتش اللينيار
- وممكن نحول المعادلة لمصفوفات تكون بالشكل ده :

$$\theta := \theta - \frac{\alpha}{m} X^T (g(X\theta) - \vec{y})$$

- الطريقة السابقة لحساب التكفة الدنيا ، تسمى الـ Gradient Descent
- لكنها ليست الطريقة الوحيدة ، هناك ثلاثة طرق اخرى وهي :
 - Conjugate Gradient
 - BFGS
 - L-BFGS
- وتلك الطرق هي افضل و اسرع لحساب التكفة الدنيا ، كما انها لا تحتاج الي حساب لقيمة الفا ، لكنها اصعب و اكثر تعقيدا
- و لاحظ ان الكود و الخوارزم الخاص بالطرق الثلاثة ديه معقد كتير ، وكتير من الناس شغالين عليه عادي من غير ما يعرفو آلية الخوارزم ايه

```

function [JVal, gradient] = costFunction(theta)
    JVal = (theta(1)-5)^2 + (theta(2)-5)^2;

    gradient = zeros(2,1);
    gradient(1) = 2*(theta(1)-5);
    gradient(2) = 2*(theta(2)-5);
end

```

- الاول هنا دالة اسمها cost function اللي هيكون فيها مدخل واحد هو الثيتا ، ومخرجين الـ J ، gradient

- لاحظ ان اول كلمة فنكشن عشان الاوكتيف يعرف هي ايه , بعدها باكتب الحاجات اللي هتخرج منها , بعدها يساوي , بعدها اسم الدالة اللي هيستخدم , بعدها المدخل (ثيتا)
- قيمة الجي فيل , ه تكون بناء على الفرض الخاص بالثيتا 1 و 2 , ونجيب الجرادينت بنفس الطريقة
- بعدها نروح علي دالة الحساب

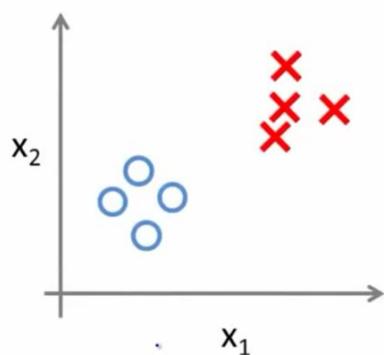
```
options = optimset('GradObj', 'on', 'MaxIter', 100);
initialTheta = zeros(2,1);
[optTheta, functionVal, exitFlag] = fminunc(@costFunction, initialTheta,
options);
```

- الاوبشنز : مجموعة من الارقام زي الفيكتور , هتساوي اللي هيطلع من اوبيتمسيت اوبيتمسيت , دالة بتعطليها الحاجات ديه , عشان تجيب الاوبشنز الثيتات الاولى صفرین
 - القيم ديه [optTheta, functionVal, exitFlag] علي الشمال عشان يتحط فيها القيم اللي هتطلع من الفنكشن علي اليمين
 - الدالة fminunc وهي المستخدمة بالخوارزمات المعقدة لحساب قيمة الثيتات المستخدمة لحساب اقل قيمة لل L و يكون مدخلاتها دالة الفنكشن و و الينات و الاوبشنز
-

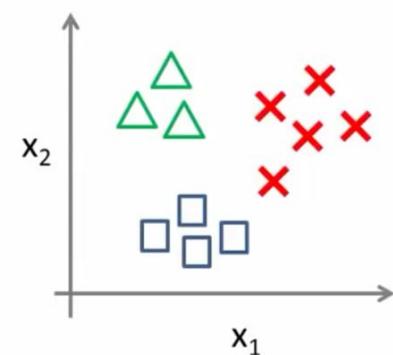
● عملية الـ MultiClass Classification

- معناها ان يتم تقسيم المنتجات الي اقسام عديدة , مش بس 0 و 1 , يعني مثلا ايميل جالك , يا تري هيروح ملف الشغل و لا الاسرة , ولا السفر ولا ايه ؟
- نفس الموضوع , المريض تشخيصه ايه : مريض بالبرد , بالحمي , بالنقرص , غير مريض
- و بدل ما كانت في النوع الاول قيمة واي هي 0 و 1 , دلوقتي بقى فيه اكتر من واي

Binary classification:

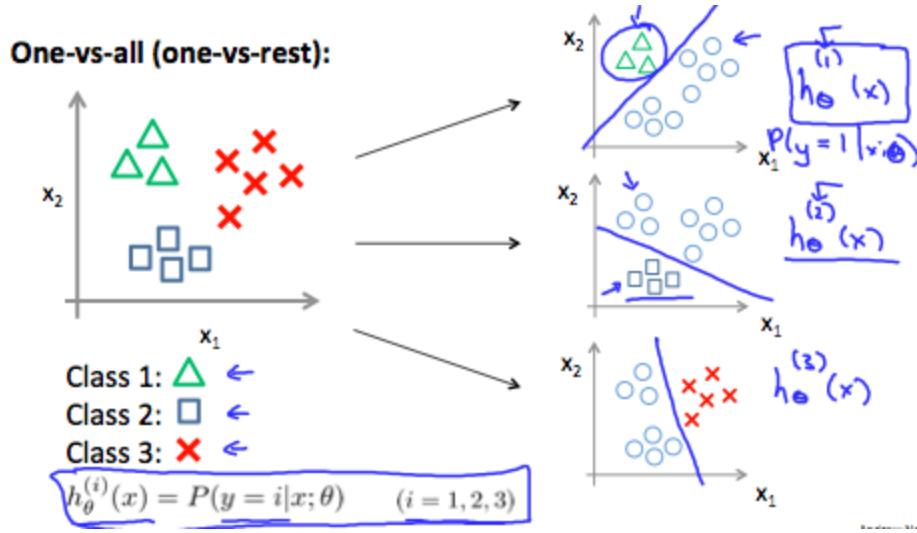


Multi-class classification:



- و بدل ما كان الرسم زي الشمال يتراوح بين عنصرين , بقى بين اكتر من عنصرين

- طب هيتعمل ازاي ؟ بفرض ان هما 3 اقسام ؟
- الأول : هنتعامل ان النوع الاول (المثلثات) هي الحاجة المرغوبة ($y=1$), والباقي غير مرغوبة ($y=0$) و نعمل خط يخليلهم على جنب , والباقي على جنب
- بعدها نكرر نفس الموضوع علي الجزء الثاني (الصلبان) , بعدها للثالث (المربعات)
- بعدها نبدأ نحدد القيمة المرغوبة هي فيه الجزء الاول و لا الثاني ولا الثالث



• مشاكل الـ Overfitting & Underfitting

- الاشكال الثلاثة دول , تمثل نفس النقط هي هي بالضبط
- Price

Size

$\rightarrow \theta_0 + \theta_1 x$
"Underfit" "High bias"

Price

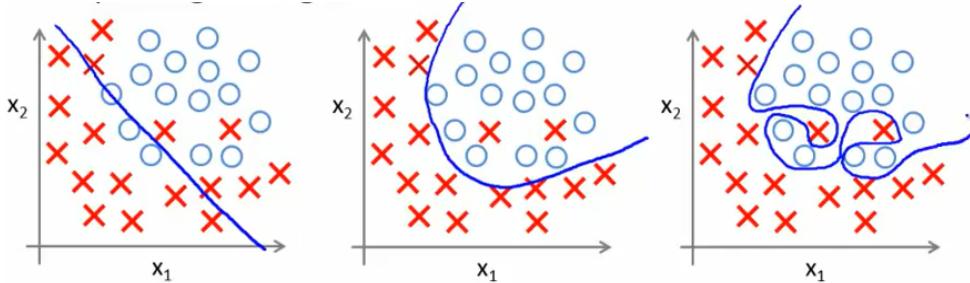
Size

$\rightarrow \theta_0 + \theta_1 x + \theta_2 x^2$

Price

Size

$\rightarrow \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$
"Overfit" "High variance"
- الشكل اليسير , نقط متفرقة , فلو عملنا اتنين ثيتا بس , هيعمل خط مستقيم , و ده هيعمل افتقار لدقة البيانات اللي هتخرج , وده اللي اسمه underfitting
- الشكل الاوسط , تم اختيار 3 ثيتا , ه تكون معادلة تربيعية , مظبوطة الي حد كبير , مع ان فيها بعض الاختلاف
- الشكل اليمين , هو المشكلة , ان الرسم ماشي مظبوط 100% مع النقط , و ده مشكلة كبيرة , لأن اي قيمة حاول اتوقعها ه تكون ماشية علي النظام القديم و ده معناه ان القيمة المتوقعة مش ه تكون سليمة



- هنعرف قدام ادوات ، للكشف على هل فيه OF او UF ولا لا طيب علاجه ايه :

- اما اننا نقل عدد المعلومات المستخدمة ، يعني نقل عدد العناصر features و نحتفظ بس بال مهم
- اختيار العناصر و ترك الباقي ممكن يتم يدويا او عبر كود معين اللي يرشح حاجات و يتغافل حاجات
- الحل الثاني هو لا regularization يعني ممكن نقول ضبط العناصر ، وهي عبر تقليل قيمة ثيتات ، وده بتستخدم لما بتعامل مع عناصر ، تاثيرها في الناتج (سعر البيت) مش كبير لكن مينفعش اتجاهله لانه مهم

● طيب عايزين نبدا نعمل لا Regularization

- الاول نشوف هل فيه بيانات هيت استبعادها و احنا شايفين انها بالفعل غير مرتبطة بالناتج ولا لا
- لو كل البيانات مرتبطة و مش هينفع نستبعد ، ممكن نقل من قيمة بعض البيانات عشان متاثرشن كتير
- فمثلا المعادلة ديه ، هيكون فيها اوفر فيتين ، ومش عايزين نتخلص من ثيتا 3 و 4 عشان قيم اكس 3 و 4 مهمين ، وفي نفس الوقت عايزين نحل الاوفر فيتينج

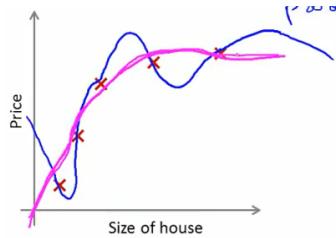
$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

- ساعتها لما نعمل معادلة الكوست فنكشن ، هنعمل رقم كبير جنب الثيتا 3 و 4 :
- $$\min_{\theta} \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + 1000 \cdot \theta_3^2 + 1000 \cdot \theta_4^2$$
- وجود رقم كبير جنب الثيتات ديه ، هتخلي قيمة ثيتا 3 و 4 اقل ما يكون ، عشان المعامل جنبهم كبير جدا ، وده اللي هيادي ان المعادلة الاصلية مش هيكون فيها اوفر فيتينج ، لأن وجود ثيتا 3 و 4 كانه اختفي

- طريقة تانية ، هي اضيف في معادلة الكوست الـ J ، اضيف ليها مجموع كل الثيتات (باستثناء ثيتا صفر ، مع ضربها في معامل اسمه لمدا)

$$\min_{\theta} \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2$$

- وجود اللمنا اللي بنسميه regularization factor بيعمل تعميم و ضبط للشكل المتعوج من اللون الازرق اللي هو اوفر فيتينج ، اللون الاحمر اللي هو سليم



- و متنساش انك لو اخترت لمدا قيمة كبيرة ، هتخلي الاكوشن تقل كل قيم الثيتات (عدا ثيتا صفر اللي مش مجموعه معاهم) لغاية لما توصل قرب الصفر ، وده هيخللي ان الإتش (القيمة المتوقعة المطلوبة) ه تكون بتساوي ثيتا صفر ، ومعناها خط افقي و طبعا ده غلط لانه اندر فيتنيج
- فصيغة معادلة الكوست ، ه تكون كدة بعد اضافة لمدا

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

- و لازم يتم فصل المعادلة لمعادلتين ، لأن الثيتا صفر مش محسوبة معانا ، فالمعادلة الاولى لثيتا صفر من غير اضافة لمدا ، والثانية لكل الثيتات ، مع اضافة لمدا

```

Repeat {
     $\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_0^{(i)}$ 
     $\theta_j := \theta_j - \alpha \left[ \left( \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} \right) + \frac{\lambda}{m} \theta_j \right] \quad j \in \{1, 2, \dots, n\}$ 
}

```

- هنمسك المعادلة الثانية نختصرها شوية هتبقي :

$$\theta_j := \theta_j \left(1 - \alpha \frac{\lambda}{m} \right) - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

- و لاحظ ان كلا من الفا و لمدا و ام ارقام موجبة ، يعني كدة ان قيمة الفا في لمدا على ام لازم تكون موجب ، يعني 1 ناقص القيمة ديه هيكون اقل من 1 . غالبا بيكون رقم اقل من 1 ب حاجة بسيطة ، مثلا 0.99 ، فلما تتضرب في ثيتا علي اليمين ، بتقلل قيمتها شوية و هكذا لغاية لما توصل لثيتا السليمة

- طيب ماذا عن طريقة النورمال ؟ اللي هي تعمل تقاضل للمعادلة و نساويها بالصفر فورا ؟
- طريقة اللينيار ، كانت المعادلة كدة زي ما هي موجودة فوق

$$\theta = (X^T X)^{-1} X^T y$$

- دلوقي عشان فيه موضوع اللمنا ، فهيهحصل تغيير انها ه تكون كدة

$$\theta = \left(X^T X + \lambda \begin{bmatrix} 0 & & & \\ & 1 & & \\ & & 1 & \\ & & & \ddots \\ & & & & 1 \end{bmatrix} \right)^{-1} X^T y$$

- مع اعتبار ان الماتريكس اللي جنب اللما ، هي ماتريكس مربعة ، طولها و عرضها ، يساوي $n+1$ و كل عناصرها صفر ، عدا المحور كله وحيد ، لكن اول صف و عمود برضه صفر (كأنها مصفوفة Identity بس اول قيمة صفر)
- يعني لو عدد العناصر ثلاثة ، هتكون المصفوفة :

Matrix A:

$$\begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

- وخد بالك ان من عيوب طريقة النورمال ان احيانا الماتريكس الداخلية تكون سينجل ، يعني مش هيتعملها انفرس ، لكن من حسن الحظ ان اضافة الماتريكس الجديدة مضروبة في لاما ، هتمنعها من انها تكون سنجلا

• وختاما ، هندخل في الفنكشن المهمة : **fminunc**

Advanced optimization

```

fminunc (or costFunction) → [θ₀ θ₁ θ₂ ... θₙ] ← theta(1) ←
function [jVal, gradient] = costFunction(theta)
    jVal = [code to compute J(θ)];
    → J(θ) = [ -½ ∑i=1m y(i) log(hθ(x(i))) + (1 - y(i)) log 1 - hθ(x(i)) ] + [½ ∑j=1n θj2]
    → gradient(1) = [code to compute ∂/∂θ₀ J(θ)];
        1/m ∑i=1m (hθ(x(i)) - y(i)) x0(i) ←
    → gradient(2) = [code to compute ∂/∂θ₁ J(θ)];
        1/m ∑i=1m (hθ(x(i)) - y(i)) x1(i) + λ/m θ1
    → gradient(3) = [code to compute ∂/∂θ₂ J(θ)];
        1/m ∑i=1m (hθ(x(i)) - y(i)) x2(i) + λ/m θ2
    :
    gradient(n+1) = [code to compute ∂/∂θₙ J(θ)];

```

- الفنكشن **fminunc** عشان تشتعل ، لازم نحدد كود الفنكشن **cost function** اللي هي بتسخدمها معاهها
- الفنكشن مكتوبة فوق ان هي بتسخدم معلومتين عشان تشتعل : **jval & gradient** :
- الـ **jval** هي لحساب قيمة الـ **θ** و هي عن طريق الدالة اللوغاريتمية ، مضاف اليها قيمة اللما الجديدة
- الـ **gradient** (وهي قيمة الثيتات) ، تتقسم لكذا حاجة

- ثيتا صفر , وهي لا تتدخل مع المدا , فتكتب بالشكل اللي هنا
- ثيتا 1 , وهي نفس صيغة ثيتا صفر مضاف اليها قيمة المدا
- باقي الثيتات زي ثيتا 1
- متساش ان كل دوال الجرادينت , هي عبارة عن تقاضل جزئي لدوال الـ L بالنسبة لثيتا المطلوبة

○ و اخيرا , دالة الكوست قبل الـ regulation هيكون شكلها كدة

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))]$$

○ وبعد الريجيولاشن هتكون كدة

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

- الاختبار الثاني :
- الفكرة :

- توجد نتائج اختبارين , وبعدها رقم يوضح هل تم قبوله بالجامعة ام لا , الرقمين الاولين هما x_1 , x_2
- رقم القبول هو y والذى هو 1 او 0
- نبدا في الشاشة الرئيسية , حيث يتم تحميل البيانات

Ex2()	
data = load('ex2data1.txt');	تحميل البيانات في مصفوفة اسمها داتا 100 ص - 3 ع
X = data(:, [1, 2]);	تحديد مصفوفة اكس بكل صفوف الداتا والعمودين الاول والثاني 100 ص-2 ع
y = data(:, 3);	مصفوفة واي بالعمود الثالث فقط 100 ص - 1 ع
plotData(X, y);	الامر بالرسم
PlotData()	
figure; hold on; pos = find(y==1); neg = find(y == 0); plot(X(pos, 1), X(pos, 2), 'k+', 'LineWidth', 2, 'MarkerSize',	الأمر بالرسم ولا تعين مين الموجب و مين السالب

<pre>7); plot(X(neg, 1), X(neg, 2), 'ko', 'MarkerFaceColor', 'y', 'MarkerSize', 7);</pre>	بعدها تحديد رسم النقط الموجبة بشكل معين و السالية بشكل اخر
---	---

هروح مؤقتا للدالة سigmoid نفهمها

Sigmoid()

$$g(z) = \frac{1}{1 + e^{-z}}.$$

<pre>function g = sigmoid(z)</pre>	الداخل و الخارج منها هي مصفوفة بنفس مقاس z التي هي هن تكون بنفس مقاس اكس الجديدة ع ص - 3 ع 100
<pre>g = zeros(size(z));</pre>	وضع قيم لـ g وهي مصفوفة مطابقة للمدخل ع ص - 3 ع 100
<pre>A1 = e .^ (-z);</pre>	ايه 1 مصفوفة بنفس القياس 3-100 , وهي قيمة اكسبيونيشيال اس ناقص زي
<pre>A2 = ones(size(z)) + A1;</pre>	ايه 2 : مصفوفة بنفس القياس 3-100 , وهي اضافة وحيد للإيه 1
<pre>A3 = 1./A2;</pre>	ايه 3 : نفس القياس 3-100 وهي مقلوب كل الارقام في ايه 2
<pre>g = A3;</pre>	نضع ايه 3 في المخرج
<pre>one = ones((size(z))); g = one ./ (one + e .^ (-z));</pre>	بديل : يمكن ان نضع السطرين دول مكانهم

Ex2()

<pre>hold on; xlabel('Exam 1 score') ylabel('Exam 2 score') legend('Admitted', 'Not admitted') hold off; fprintf('\nProgram paused. Press enter to continue.\n'); pause;</pre>	عرض اسماء الصفوف و الاعمدة في الرسم
<pre>[m, n] = size(X);</pre>	تحديد ابعاد الالكس m=100 n=2
<pre>X = [ones(m, 1) X];</pre>	اضافة عمود جديد شمال الالكس فيه الوحيد (عشان ثيتا 0)

	اكس بقت 100 ص - 3 ع
initial_theta = zeros(n + 1, 1);	تحديد قيم اوليه لثيتا 3 ص - 1 ع
[cost, grad] = costFunction(initial_theta, X, y);	قيمتين واحدة للتكلفة و الثانية للثيتات ، و هنتيجي من الدالة كوست فنكشن مدخلاتها هي : الثيتات الاولى اصفار (3 ص - 1 ع) إكس (100 ص - 3 ع) واي (100 ص - 1 ع)
costfunction()	
$J(\theta) = \frac{1}{m} \sum_{i=1}^m \left[-y^{(i)} \log(h_\theta(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)})) \right],$	
one = ones(m,1);	تحديد صفرة وحيد ، 100 صف في عمود واحد
g = sigmoid(X * theta);	السيجمويد هتخرج لنا مصفوفة 100 صف في عمود واحد ، و اللي هيتحط اس للاكبسونيشمال لازم يكون محصرة ضرب الاكستات و الثيتات ، فهنهضرب مصفوفة اكس (1-100) في مصفوفة ثيتا (1-3) ، هتكون (1-100) و السيجمويند هتجيبينا قيمهم اللي تتراوح بين 0 و 1 ، في مصفوفة طويلة 100 في 1
$J = \frac{1}{m} * ((\log(g))' * -y) - ((\log((one - g)))' * (one - y));$	عشان نجيب قيمة لوج السيجمويند (1-100) مضروب في واي ، نعمل للسيجمويند ترانسبوز (100-1) ونضربها في الواي (100-1) تعمل لنا قيمة مباشرة لحاصل ضربهم ، ومننساش السالب
	الجزء الثاني ، نجيب لوج السيجمويند بعد ما اطرح منها واحايد (1-100) ، ونعمل لها ترانزبوس (100-1) ، وبعدها نضربها في الوايات لما نطرح منها واحايد (1-100)
grad = 1/m * X' * (sigmoid(X * theta) - y); $\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$	هجيب السيجمويند (1-100) و اطرح منها الوايات ، بعدها نضرب في ترانسبوز الاكس يعني ترانسبوز الاكس (100-3) في (100-1) ، يعملي (1-3) و اقسمها على الام

Ex2()

```
fprintf('Cost at initial theta (zeros): %f\n', cost);
fprintf('Expected cost (approx): 0.693\n');
fprintf('Gradient at initial theta (zeros): \n');
fprintf(' %f \n', grad);
fprintf('Expected gradients (approx):\n -0.1000\n
-12.0092\n -11.2628\n');
```

```
test_theta = [-24; 0.2; 0.2];
[cost, grad] = costFunction(test_theta, X, y);

fprintf('\nCost at test theta: %f\n', cost);
fprintf('Expected cost (approx): 0.218\n');
fprintf('Gradient at test theta: \n');
fprintf(' %f \n', grad);
fprintf('Expected gradients (approx):\n 0.043\n 2.566\n
2.647\n');
fprintf('\nProgram paused. Press enter to continue.\n');
pause;
```

عرض البيانات ، وقيم الجي و الثيتات في حالتين

fminunc الدالة

وهي دالة بديلة للي عملناه فوق ، لأن هي بلت ان في الاوكتيف
و هي محتاجة كذا حاجة عشان تشتعل :

- المعلومات اللي طالعة من كوسن فنكشن (كوسن ، جريد)
- القيم الاولى لثيتا
- معلومات الاوبشنز

```
options = optimset('GradObj', 'on', 'MaxIter', 400);
```

اوبيشنز ، فيكتور من كذا معلومة ، وتم اعلامه
أن خيار جريد شغال (عشان يرجع قيم) ، وان
اقصي عدد للمحاولات 400

```
[theta, cost] = fminunc(@(t)(costFunction(t, X, y)),
initial_theta, options);
```

هنا اكتب المخرجت الاول (ثيتا ، الكوسن)
يساوي دالة fminunc بعدها انادي علي الدالة
الكوسن ، مع قيم ثيتا ، والاوبيشنز اللي فوق